



Univerzitet u Beogradu – Elektrotehnički fakultet

Katedra za signale i sisteme



Projektni zadatak

Sistemi odlučivanja u medicini

Tema 08 - Heart Disease Data Set


Studenti

Katarina Bojović 2022/0239

Tijana Aksoović 2022/0224

1. Analiza podataka

Baza se sastoji od 5 klasa, numerisanih od 0 do 4. Zdrava osoba je označena sa 0, dok je sa 1-4 odnačeno postojanje neke bolesti srca kod osobe.



Ukupno ima 920 uzoraka. Svaki uzorak ima 13 atributa:

age: starost

sex: pol (1 = muški; 0 = ženski)

cp: tip bola u grudima (1, 2, 3, 4)

trestbps: krvni pritisak

chol: količina holesterola u krvi [mg/dl]

fbs: količina šećera u krvi (1 = true; 0 = false)

restecg: EKG u mirovanju (0 – normalan, 1-ST abnormalan talas, 2- hipertrofija leve komore)

thalach: maksimalna frekvencija srca

exang: angina izazvana vežbanjem (1 = da; 0 = ne)

oldpeak = ST depresije u toku vežbanja u odnosu na odmor


slope: nagib ST depresije

ca: broj glavnih krvnih sudova

thal: nedostaci (3 = normalno; 6 = fiksni defekt; 7 = reverzibilni defekt)

num: dijagnoza srčane bolesti (0- nema bolesti, 1,2,3,4- prisustvo bolesti)

Analizom podataka smo dobili da postoje neadekvatne vrednosti u bazi podataka. Neadekvatne vrednosti koje se pojavljuju su 0 kod trestbps, chol i thalach i ? zamenili smo sa NaN. Daljom analizom smo dobili da kolone ca i thal imaju preko 50% NaN vrednosti, pa ćemo ih u potpunosti ukloniti. U ostalim kolonama, nepoznate vrednosti menjamo sa najčešćom (za diskretne slučajne promenljive) i medijanom (za kontinualne slučajne promenljive).



Histogram atributa nakon dopune podata

2. Selekcija obeležja


-Informaciona dobit (IG) za svako obeležje:

Obeležje	IG
cp	0.233486
oldpeak	0.163578
thalach	0.148545
exang	0.146432
age	0.113623
sex	0.070653
trestbps	0.044644
slope	0.042199
chol	0.033108
restecg	0.029446
fbs	0.013433


Analizom informacione dobiti vidimo da je najinformativnije obeležje cp, a da su oldpeak i thalach odmah iza njega. Za dalju analizu izdvojicemo deset najinformativnijih obeležja. U našem slučaju samo će obeležje fbs biti izbačeno iz dalje analize.

-Analiza korelacije

Na osnovu deset izdvojenih obeležja i izlazne klase izračunata je međusobna korelacija. Najpre je korišćena Pearson-ova, a zatim Spearmano-ova korelaciona metoda.



Matrica Pearson-ovih koeficijenata korelacije




Matrica Spearman-ovih koeficijenata korelacije

Sa matrica korelacija zaključujemo da su obeležja cp i oldpeak u najvećoj korelaciji sa izlaznom klasom i u slučaju Pearson-ove i u slučaju Spearmano-ove korelacione metode, što se poklapa i sa rezultatima koje smo dobili preko informacione dobiti.

- Raspodela uzoraka


Grafici uzoraka po klasama za dva obeležja koja su pokazala najveću korelaciju, a ujedno i najveći IG sa izlaznom klasom : cp i oldpeak.

Klasa x cp (broj uzoraka)




Raspodela uzoraka po klasama za obeležje cp

Klasa x oldpeak (broj uzoraka)




Raspodela uzoraka po klasama za obeležje oldpeak

3. Redukcija dimenzija



Na osnovu dobijenih podataka vidimo da je indeks informativnosti uvek veći od 80% , pa je svaki odabir adekvatan. S obzirom da imamo 5 klasa, maksimalan broj komponenti koje mozemo uzeti je 4, a minimalan 1.




Korišćenjem 2 i 3 komponente vidimo da naš problem nije separabilan. Ipak, može se primetiti da je klasa 0, koja predstavlja zdrave osobe, relativno dobro odvojena od ostalih. Zbog toga, i zbog nebalansiranosti klasa, u daljoj analizi ćemo sve klase koje predstavljaju bolesne osobe (klase 1-4) spojiti u jednu klasu, klasu bolesnih (1), i raditi sa dve klase. Na taj način ćemo dobiti model koji predviđa prisustvo bolesti, ali ne i njen stepen ozbiljnosti. Za model koji bi mogao da razlikuje stepene bolesti bilo bi potrebno više podataka i dodatna obeležja koja bi ih bolje razdvojila. Daljom analizom smo utvrdili da se ni sa dve klase se ne dobija separabilan problem, ali je rezultat značajno bolji, tako da ćemo pokušati da ovakav skup podelimo nekom od parametarskih metoda klasifikacije.

4. Testiranje hipoteza

S obzirom da radimo sa realnim odabircima, ne znamo njihovu raspodelu. Stoga, klasifikator projektujemo tako što ceo ulazni skup podelimo na trening i test skup, i onda trening skup koristimo za procenu parametara (μ i δ), a test skup za proveru uspešnosti klasifikatora. Pri tom pretpostavljamo normalnu raspodelu podataka.

U našem slučaju postoje 2 klase, zdravi i bolesni, a pošto je u medicini mnogo važnije da nekoga ko je bolestan ne proglasimo zdravim nego obrnuto, koristićemo Bajesov klasifikator minimalne cene. Za cenu c_{12} ćemo staviti 10 puta veću vrednost kako bismo to postigli.




Konfuziona matrica i parametri evaluacije Bajesovog klasifikatora minimalne cene

Tacnost klasifikacije	76.76%
Preciznost klasifikacije	76.58%
Senzitivnost klasifikacije	83.33%
Specifichnost klasifikacije	68.67%
Stopa lažno negativnih	16.67%


5. Neparametarska klasifikacija

Od neparametarskih metoda, između algoritma K najbližih suseda i stabla odlučivanja izabrali smo K najbližih suseda, jer nam je granica između klasa nelinearna i skup podataka nije toliko veliki.



Grafik zavisnosti tačnosti klasifikacije od optimizacionog parametra

Najbolja tačnost se dobija za K=11 i iznosi 69.38%.





Konfuzionna matrica i parametri evaluacije KNN klasifikatora

Tacnost klasifikacije	69.38%
Preciznost klasifikacije	69.00%
Senzitivnost klasifikacije	81.18%
Specificnost klasifikacije	54.74%
Stopa lažno negativnih	18.82%

6. Neuralna mreža

Ulazni sloj ima onoliko neurona koliko imamo obeležja, u našem slučaju 10, a izlazni 1 jer imamo 2 klase. Proverom vrednosti kriterijumske funkcije na test i validacionom skupu odredićemo adekvatan broj slojeva i neurona koji daje zadovoljavajuće rezultate, a ne dovodi do preobučavanja.

-Dobro odabrana struktura





Tacnost klasifikacije	79.35%
Preciznost klasifikacije	77.12%
Senzitivnost klasifikacije	89.22%
Specifcnost klasifikacije	67.07%
Stopa lažno negativnih	10.78%

val_loss: 0.5057

S obzirom da nemamo veliki broj podataka, mreža je sklona preobučavanju. Zbog toga smo koristili samo 1 skriveni sloj od 10 neurona. Time smo postigli tačnost na test skupu od oko 80% uz 10% propuštenih detekcija (lažno negativnih) i grešku na validacionom skupu od oko 0.5. Takođe, vidimo da greška i na trening i na validacionom skupu počinje da stagnira već na oko 60 epoha tj. brzo opadne, ali ne na 0.

-Struktura sa premalim brojem neurona





Tacnost klasifikacije	65.22%
Preciznost klasifikacije	67.59%
Senzitivnost klasifikacije	71.57%
Specifcnost klasifikacije	57.32%
Stopa lažno negativnih	28.43%

val_loss: 3.5640



Za primer sa premalim brojem neurona uzeli smo najjednostavniju mrežu, samo sa ulaznim i izlaznim slojem. Vidimo da je tačnost klasifikatora značajno lošija, sa 28% lažno negativnih. Greške na trening i validacionom skupu sporije opadaju tako da je potreban veći broj epoha kako bi se stacionirale. Posle 200 epoha, greška na validacionom skupu nam je pala na 3.56 što je 7 puta veće od prethodno dobijene. Zaključujemo da je neuralna mreža sa ovakvom strukturom nedovoljno obučena.

-Struktura sa prevelikim brojem



Tacnost klasifikacije	78.80%
Preciznost klasifikacije	80.58%
Senzitivnost klasifikacije	81.37%
Specificnost klasifikacije	75.61%
Stopa lažno negativnih	18.63%

- Rano zaustavljanje





Tacnost klasifikacije	70.65%
Preciznost klasifikacije	67.14%
Senzitivnost klasifikacije	92.16%
Specificnost klasifikacije	43.90%
Stopa lažno negativnih	7.84%

val_loss: 0.5516

Rano zaustavljanje je tehnika sprečavanja preobučavanja koja podrazumeva da se obučavanje neuralne mreže zaustavi kada greška na podacima koje neuralna mreža nije videla krene da raste. Ova metoda podrazumeva da se skup podataka podeli na skup podataka za trening i skup podataka za validaciju neuralne mreže. Tokom treniranja, mreži se prosleđuju oba skupa, i paralelno se gleda greška klasifikacije na njima. Tokom treniranja greška na trening skupu će konstantno da opada, dok će greška na validacionom skupu u jednom trenutku krenuti da raste. Taj trenutak predstavlja trenutak ranog zaustavljanja.

Zaustavili smo se na 104 epohe, od 200.

- Regularizacija



Tacnost klasifikacije	79.35%
Preciznost klasifikacije	76.23%
Senzitivnost klasifikacije	91.18%
Specificnost klasifikacije	64.63%
Stopa lažno negativnih	8.82%

val_loss: 0.7554

Regularizacija služi da spreči preobučavanje neuralne mreže dodavanjem člana u kriterijumsku funkciju koji penalizuje velike vrednosti težina. Kada model ima velike težine, onda male promene ulaznih parametara dovode do velikih promena na izlazu. Postoje L1 i L2 tehnika regularizacije: L1 : $L(\omega) = E(\omega) + \lambda * \sum |\omega|$, L2 : $L(\omega) = E(\omega) + \lambda * \sum \omega^2$. Prednost L1 tehnike regularizacije je u tome što je otporna na outliere, dok je prednost L2 tehnike regularizacije to što može da nauči kompleksnije oblike podataka. Mi smo koristili L2 regularizaciju u skrivenim slojevima od 200, 200 i 100 neurona. Vidimo da je razlika između greške na trening i validacionom skupu sada manja, sa minimalnom vrednošću oko 0.7. Takođe, tačnost je povećana u odnosu na tačnost preobučene mreže.

7. Komparativna analiza

	Bajesov klasifikator minimalne cene	KNN	Neuralna mreža
Preciznost	76,58%	69,00%	77,12%
Senzitivnost	83,33%	81,18%	89,22%
Specifičnost	68,67%	54,74%	67,07%
Tačnost	76,76%	69,38%	79,35%

- Bajesov klasifikator minimalne cene

-Prednosti: najviša specifičnost (68.67%), solidna preciznost (76.58%) i tačnost (76.76%), jednostavan, lako se podešava prag

-Mane: niža senzitivnost od neuralnih mreža pa će češće promašiti bolesne, pretpostavke pod kojim radimo nisu uvek tačne

- KNN

-Prednosti: bez parametarskih pretpostavki, intuitivan

-Mane: najlošiji ukupno (tačnost 69.38%, specifičnost 54.74%) zbog malog i neuravnoteženog skupa podataka

- Neuralna mreža

-Prednosti: najbolja tačnost (79.35%) i senzitivnost (89.22%) - najbolja za detekciju bolesnih

-Mane: nešto niža specifičnost (67.07%) od Bajesovog, manje intuitivna

U poređenju metoda, Bajesov klasifikator minimalne cene pokazuje najuravnoteženije performanse (najbolja specifičnost i solidna tačnost), pa ga izdvajam kao najbolje rešenje za ovaj zadatak. Iako je neuralna mreža imala najvišu senzitivnost i tačnost, njeni rezultati su nestabilni - pri svakom ponovnom pokretanju dobijam različite metrike zbog slučajne početne inicijalizacije i stohastičnog treniranja. Kao nadogradnju rada, preporučujem k-fold validaciju i prikaz prosečnih metrika preko više pokretanja radi stabilnije i pouzdanije procene neuralne mreže.